

# Göreve Uygun Hibrit Mimariler: Metrik, Mimari ve Görev Boyutlarında Birleşik Bir Kazanç Teorisi

Erdem Esa  
Bağımsız Araştırmacı

September 24, 2026

## Abstract

Hibrit sistemler koşulsuz kazanmaz: kazançları metrik tipine, mimari tipine ve görev yapısına bağlıdır. Lineer metrikler için kesin bir özdeşlik ve makro  $F_1$  için sınıf-başına bir genişletme sunuyoruz; lineer ağırlık lineer olmayan metriklerde çökmediği için bu genişletmenin zorunlu olduğunu gösteriyoruz. Ayrıca Kronecker mimarilerinin kompozisyonel ve gerçek görüntü görevlerinde  $8 \times -12.6 \times$  daha parametre-verimli olduğunu, hiyerarşik varyansın ise görüntü-benzeri girdilerde istatistiksel olarak üstün olduğunu gösteriyoruz (50 tohum,  $p < 0.0001$ ). Bu sonuçlar hibrit sistem tasarımının ilkeli olabileceğini öne sürüyor: metrikler için formül-güdümlü, görevler için yapı-güdümlü.

## 1 Giriş

Sembolik akıl yürütme ile sinirsel öğrenmeyi birleştiren hibrit sistemler modern yapay zeka araştırmalarının merkezinde yer alıyor. Ancak bir hibrit sistemin *ne zaman* sinirsel temelinin geçtiği sorusu büyük ölçüde sezgisel kalmıştır. Önceki çalışmalar deneysel kılavuzlar önermiş, ama birleşik bir öngörü çerçevesi sunmamıştır.

Önceki çalışmamız [1], bir hibrit sembolik-sinirsel sistemin sinirsel temele karşı kazancı için, lineer metriklerde geçerli kapalı-form bir formül ortaya koydu:

$$\text{kazanç} = \text{kapsam}_{\text{sem}} \cdot (\text{doğruluk}_s - \text{doğruluk}_n), \quad (1)$$

burada  $\text{kapsam}_{\text{sem}}$  sembolik kolun kapsamı,  $\text{doğruluk}_s$  ve  $\text{doğruluk}_n$  ise sembolik ve sinirsel doğruluklardır. Bu formül 12 dil, 4 görev tipi ve 2 metrik üzerinde ortalama 0.002 öngörü hatasıyla doğrulanmıştır.

Bu çalışma, lineer formülün kapsamadığı üç açık soruyu ele alır:

1. **Metrik kapsamı.** Formül,  $F_1$  gibi lineer olmayan metriklere genellenebilir mi?
2. **Mimari seçimi.** Bilinear Kronecker mimarisi ne zaman standart yoğun MLP'ye tercih edilir?
3. **Görev yapısı.** Kazanç, görevin rastgele-lineer mi yoksa kompozisyonel mi olmasına nasıl bağlıdır?

## Katkılar.

1. Lineer formülü, makro  $F_1$  için *kesin* olan sınıf-başına bir özdeşliğe genişletiyoruz (Bölüm 3.2).

2. Kronecker mimarisinin kompozisyonel görevlerde  $8\times$  daha parametre-verimli olduğunu ve hiyerarşik Kronecker’ın görüntü-benzeri kompozisyonel görevlerde yoğun MLP’yi istatistiksel olarak yendiğini gösteriyoruz (Bölüm 3.3).
3. Görev tipini mimari seçimine eşleyen bir karar ağacı sunuyoruz, 20–50 tohumlu eşleşmiş  $t$ -testleriyle desteklenmiş.
4. Negatif sonuçları dürüstçe belgeliyoruz (Bölümler 4.6 ve 5).

**Terminoloji.** Metin boyunca üç iddia düzeyi ayırt edilir: *kesin özdeşlik* (matematiksel olarak ispatlı, örn. Denklemler 2, ??), *öngörü formülü* (deneysel olarak doğrulanmış yaklaşıklık, örn. Denklem 1) ve *hipotez* (test edilmiş ama ispatlanmamış, örn. Bölüm 3.3).

## 2 İlgili Çalışmalar

**Nörosembolik YZ.** Sembolik akıl yürütmeyi sinirsel öğrenmeyle birleştirmek uzun süredir hedeflenen bir amaçtır. Garcez ve Lamb [2] nörosembolik YZ’nin üçüncü dalgasını incelemekte, DeepProbLog [3] olasılıksal mantık programlamayı sinir ağlarıyla bütünleştirmektedir. Besold ve ark. [6] daha erken bir derleme sunar. Bizim çalışmamız, kombinasyonun *ne zaman* kazandığı sorusuna odaklanır: yeni bir bütünleşme mimarisi değil, kapalı-form bir kazanç formülü sunuyoruz.

**Kompozisyonel yapıli hibrit sistemler.** Neural Module Networks [7] ve CLEVR [8], kompozisyonel görevlerin yeniden kullanılabilir modüllere ayrılabilceğini göstermiştir. Mao ve ark. [9] bunu kavram öğrenmeye genişletmiştir. Bizim kompozisyonel görevlerimiz bunlardan esinlenmiştir; ama farklı bir soruya odaklanırsınız: bir hibrit sistem verildiğinde, sembolik kolu ne zaman yardımcı olur?

**Tensörleştirilmiş ve yapısal mimariler.** MLP-Mixer [10] ve gMLP [11] dikkati token-karıştırıcı MLP’lerle değiştirirken, ConvMixer [12] yama tabanlı evrişimlerin benzer performans verdiğini göstermektedir. Tensor Train ayrışımı [13] ve LoRA [14] verimlilik için düşük-rank yapıyı kullanır. Bizim Kronecker katmanımız bu yaklaşımlarla yakından ilişkilidir; ancak yeni bir katman önermek yerine *görev-uygunluğu* inceliyoruz.

**Dikkat ve görüntü transformatörleri.** Transformer [5] ve görüntü varyantı ViT [15] dikkati genel amaçlı bir operatör olarak konumlandırmıştır. Bizim çalışmamız dikkatle rekabet etmez; bunun yerine *yapısal* bir alternatifi (Kronecker) *yapısız* bir temele (yoğun MLP) ne zaman tercih edileceğini karakterize eder.

**Diller arası NLP.** Universal Dependencies [4] doğrulamamızda kullanılan çok dilli ağaç bankalarını sağlar. İTÜ Türkçe NLP Pipeline [16], morfolojik olarak zengin bir dil için kurallı tabanlı sembolik bir sistemin kanonik bir örneğidir ve Türkçe’yi on iki doğrulama dilinden biri olarak seçmemize ilham kaynağı olmuştur.

**Metrikler ve ayrışimleri.** Sokolova ve Lapalme [17] performans ölçütlerinin sistematik bir analizini sunar, Opitz ve Burst [18] özellikle makro  $F_1$ ’i ele alır. Grandini ve ark. [19] çok-sınıflı metrikleri derinlemesine karşılaştırır. Bizim sınıf-başına özdeşliğimiz, bildiğimiz kadarıyla, hibrit  $F_1$ ’in sınıf-başına ağırlıklar cinsinden ilk kesin ayrışımıdır.

**İstatistiksel metodoloji.** Çoklu karşılaştırma düzeltmesi [20] ve etki büyüklüğü raporlaması [21] için standart uygulamayı izliyoruz.

### 3 Teori

#### 3.1 Lineer Metrik Formülü

$s(x) \in \{0, 1, \perp\}$  sembolik kolun çıktısı olsun;  $\perp$  çekimserliği belirtir.  $n(x) \in \{0, 1\}$  ise sinirsel kolun çıktısıdır. Hibrit kural:  $h(x) = s(x)$  eğer  $s(x) \neq \perp$ , aksi halde  $n(x)$ .

Kapsam  $\text{kapsam} = \Pr[s(x) \neq \perp]$  ve  $\text{doğ}_n^\perp = \Pr[n(x) = y \mid s(x) = \perp]$  tanımlanır. Öge-bazlı doğruluk göstergesinde *lineer* olan herhangi bir  $M$  metriği için, hibritin değeri tam olarak ayrıştır:

$$M_h = \text{kapsam} \cdot M_s + (1 - \text{kapsam}) \cdot M_n^\perp. \quad (2)$$

$M_n = \text{kapsam} \cdot M_n + (1 - \text{kapsam}) \cdot M_n$  teleskopik özdeşliğini çıkararak kazanç formülünü elde ederiz:

$$\text{kazanç} = \text{kapsam} \cdot (M_s - M_n) + (1 - \text{kapsam}) \cdot (M_n^\perp - M_n). \quad (3)$$

$M_n^\perp \approx M_n$  olduğunda ikinci terim ihmal edilir; artık hata  $\varepsilon = (1 - \text{kapsam}) \cdot |M_n^\perp - M_n|$  ile sınırlıdır.

#### 3.2 $F_1$ Sınıf-Başına Formülü

$F_1$  harmonik ortalama içerdiği için lineer değildir; lineer formül  $F_1$ 'de bozulur. Tek-etiketli sınıflandırmada *kesin* ayrışım:

$$F_1^h = \frac{1}{K} \sum_{c=1}^K [w_c \cdot F_{1s}^c + (1 - w_c) \cdot F_{1n}^c], \quad (4)$$

burada sınıf-başına ağırlık

$$w_c = \frac{D_s^c}{D_s^c + D_n^c}, \quad D_k^c = 2 \cdot \text{TP}_k^c + \text{FP}_k^c + \text{FN}_k^c. \quad (5)$$

Kritik gözlem:  $w_c \neq \text{kapsam}$ ; sınıf-başına ağırlıklar sınıf dağılımına bağlıdır. Bu, lineer formülün  $F_1$ 'de neden bozulduğunu kesin olarak açıklar.

**Neden önemli.** Denklem ??  $F_1$  tanımının cebirsel bir sonucu olsa da, *öngörü* içeriği önemsiz değildir: sınıf-başına ağırlıklar  $w^c$  sınıflar arasında değişir (NER deneylerimizde deneysel olarak 0.37–0.66 aralığında), lineer formül ise tek bir ağırlık kapsam varsayar. Bu nedenle özdeşlik, lineer formülün hatasının neden büyük olduğunu ( $\varepsilon \approx 0.019$ ) açıklar ve yapıcı bir çözüm sunar.

#### 3.3 Kronecker Görev-Uygunluk

Bilinear Kronecker katmanı  $Y = AXB$  hesaplar,  $X \in \mathbb{R}^{n \times n}$  için. Düzleştirilmiş biçimde  $Y_{\text{vec}} = (B^\top \otimes A)X_{\text{vec}}$ ,  $n^2 \times n^2$  boyutlu bir lineer operatördür ve yalnızca  $2n^2$  eğitilebilir parametreyle temsil edilir. Operatörün rankı  $\text{rank}(A) \cdot \text{rank}(B) = n^2$  (tam rank), ama serbestlik derecesi  $2n^2$  olarak kalır.

Bu yapısal kısıt, görevin kendi yapısı tensör ayrışımıyla uyumlu olduğunda bir *özellik* haline gelir:

**Çalışma Hipotezi (sonradan gözden geçirildi).** Başlangıçta Kronecker mimarilerinin, görevin fonksiyonel bağımlılıkları  $X \mapsto AXB$  tensör faktörizasyonuna uyduğunda parametre-verimli olduğunu öne sürdük. Bölüm ??, bu *yapısal uyum* hipotezinin reddedildiğini ve gerçek mekanizmanın parametre kısıtı yoluyla örtük düzenleştirme olduğunu gösterir.

## 4 Deneyler

### 4.1 Lineer Metrik Doğrulaması

Denklem 1, 8 dil ailesine yayılmış 12 veri kümesinde, 4 yazı sisteminde (Latin, Han, Kiril, Arap) ve 4 görev tipinde (ikili bağımlılık doğrulaması, çok-sınıflı, çok-etiketli, NER) doğrulandı. Tablo 1 toplu hatayı özetler.

Table 1: Lineer metrik formülü doğrulaması. Tüm konfigürasyonlarda ortalama öngörü hatası.

| Boyut           | Kapsam                                    |
|-----------------|-------------------------------------------|
| Diller          | 12 (8 aile)                               |
| Yazı sistemleri | 4 (Latin, Han, Kiril, Arap)               |
| Görev tipleri   | 4 (ikili, çok-sınıflı, çok-etiketli, NER) |
| Metrikler       | 2 (doğruluk, bit-doğruluğu)               |
| Ortalama hata   | 0.002                                     |
| Maksimum hata   | 0.008                                     |

Sembolik gürültü altında (%0-%50), formülün öngörü hatası  $\varepsilon = 0.0066$  değerinde değişmeden kalır; bu, lineer özdeşliğin hibrit topluluğun yapısal bir özelliğini yakaladığını gösterir.

**Yeniden üretilebilirlik.** Kaynak: `artifacts/TWELVE_LANGUAGE_FORMULA.md`, `artifacts/SYMBOLIC_NOISE`  
Betik: `artifacts/symbolic_noise_robustness.py`.

### 4.2 $F_1$ Sınıf-Başına Doğrulaması

Lineer formül  $F_1$ 'de başarısız olur; çünkü  $F_1$  harmonik ortalama içerir ve öge-bazlı doğruluk göstergesinde lineer değildir. Bunu 20 NER konfigürasyonunda (5 tohum  $\times$  4 gizli oran) test ettik.

Table 2: 20 NER konfigürasyonunda  $F_1$  formül karşılaştırması. Lineer formül ağırlık olarak kapsam kullanır; sınıf-başına formül  $w_c = D_s^c / (D_s^c + D_n^c)$  kullanır.

| Formül                           | Ortalama $\varepsilon$ | Maksimum $\varepsilon$ |
|----------------------------------|------------------------|------------------------|
| Lineer (kapsam-ağırlıklı)        | 0.0188                 | 0.0515                 |
| Sınıf-başına ( $w_c$ -ağırlıklı) | 0.000000               | 0.000000               |

Sınıf-başına formül 20 konfigürasyonun tümünde makine hassasiyetinde hata verir; bu, genişletmenin makro  $F_1$  için kesin olduğunu doğrular.

**Yeniden üretilebilirlik.** Kaynak: `artifacts/F1_HARMONIC_FORMULA_FINAL.md`. Betik: `artifacts/f1_per`  
(tohum 1–5, gizli oranlar {0.10, 0.30, 0.50, 0.70}).

### 4.3 Kronecker Görev-Uygunluk Sonuçları

Görev-uygunluk hipotezini üç görev tipinde test ettik: rastgele lineer öğretmen (sentetik), basit kompozisyonel görev (blok güçleri) ve görüntü-benzeri kompozisyonel görev (uzamsal korelasyonlu 2D grid). Tablo 3 her durumda kazanımı özetler.

**Basit kompozisyonel.** 20 tohum. Düz Kronecker (2,564 parametre)  $0.8007 \pm 0.0202$  sonucuna ulaşırken, Yoğun MLP (20,868 parametre)  $0.7982 \pm 0.0190$  elde ediyor; fark anlamlı değil ( $p = 0.52$ ). Hiyerarşik Kronecker (87,044 parametre) 0.7872'ye ulaşır ve düzden *anlamlı olarak daha kötüdür* ( $p = 0.0008$ , Cohen  $d = -0.75$ ).

Table 3: Görev tipine göre kazanan. Parametre sayıları parantez içindedir. İstatistiksel testler: eşleşmiş tohumlarda  $t$ -testi.

| Görev tipi            | Kazanan        | Test Doğ. | Verimlilik       |
|-----------------------|----------------|-----------|------------------|
| Rastgele lineer       | Yoğun MLP      | —         | temel            |
| Basit kompozisyonel   | Düz Kronecker  | 0.8007    | $8\times$ az     |
| Görüntü kompozisyonel | Hiy. Kronecker | 0.8360    | $34\times$ fazla |

**Görüntü kompozisyonel.** 50 tohum. Hiyerarşik Kronecker  $0.8360 \pm 0.0217$  sonucuna ulaşırken, Yoğun MLP  $0.8190 \pm 0.0198$  (eşleşmiş  $t$ -testi:  $p < 0.0001$ , Cohen  $d = -1.37$ ). Düz Kronecker (2,564 parametre) 0.8267’ye ulaşır ve Yoğun MLP’den anlamlı olarak iyidir ( $p = 0.0003$ ,  $d = +0.51$ ); bu,  $8\times$  parametre verimliliğini küçük bir mutlak doğruluk avantajıyla gösterir.

İki kompozisyonel görev arasındaki karşıtlık—basit bloklar ve uzamsal korelasyonlu görüntübenzeri gridler—Kronecker’in avantajının görev ile tensör faktörizasyonu arasındaki *yapısal uyumun derecesine* bağlı olduğunu gösterir.

**Yeniden üretilebilirlik.** Kaynaklar: `artifacts/COMPOSITIONAL_KRONECKER_WIN.md`, `artifacts/IMAGE_COMPOSITIONAL.md`. Betikler: `artifacts/compositional_20seed.py` (tohum 1–20), `artifacts/image_compositional.py` (tohum 1–50).

#### 4.4 Gerçek Görüntü Doğrulaması (MNIST)

Görev-uygunluk hipotezinin sentetik gridlerin ötesine geçip geçmediğini test etmek için MNIST ( $28 \times 28$  gri-ton rakamlar) üzerinde değerlendirdik. 2000 örnekle eğitip 500 örnekle 30 epoch boyunca test ettik.

Table 4: MNIST sonuçları (5 tohum). Düz Kronecker, en büyük Yoğun MLP’den  $12.6\times$  daha az parametreyle rekabetçi doğruluğa ulaşır.

| Model                     | Parametre | Test Doğruluğu    |
|---------------------------|-----------|-------------------|
| Yoğun MLP ( $h = 32$ )    | 26,506    | $0.594 \pm 0.056$ |
| Yoğun MLP ( $h = 128$ )   | 118,282   | $0.808 \pm 0.017$ |
| Düz Kronecker ( $K = 1$ ) | 9,418     | $0.770 \pm 0.013$ |
| Düz Kronecker ( $K = 2$ ) | 10,986    | $0.717 \pm 0.041$ |
| Düz Kronecker ( $K = 3$ ) | 12,554    | $0.662 \pm 0.048$ |

**Bulgular.** (1) *Parametre verimliliği gerçek görüntülere de uzanır:* Düz Kronecker (9,418 param) 0.770’a ulaşırken, Yoğun MLP (118,282 param) 0.808’de kalır —  $12.6\times$  azaltma, %3.8 doğruluk farkıyla. (2) *Derinlik çöküşü evrenseldir:* hem sentetik hem gerçek veride  $K = 1$  en iyidir,  $K > 1$  daha kötüdür. Bu, çöküşün yapısal olduğunu doğrular. (3) *Yapısal kısıt düzenleştiricidir:* Yoğun MLP  $h = 32$  (26,506 param) Düz Kronecker’in 9,418 parametrelili sürümünden daha kötü performans verir; bu Kronecker kısıtının örtük bir düzenleştirici olduğunu öne sürer.

**Dürüst sınır.** Mutlak doğruluk farkı (%3.8) devam ediyor. Kronecker verimlidir, baskın değil.

**Yeniden üretilebilirlik.** Kaynak: `artifacts/MNIST_KRONECKER.md`. Betik: `artifacts/mnist_kronecker.py` (tohum 1–5, MNIST `data/mnist/` dizininden yüklenir).

## 4.5 Parametre-Eşleşmeli Karşılaştırma

$8\times$  verimlilik iddiası, Kronecker ve Yoğun MLP’yi *doğal parametre sayılarında* karşılaştırır. Verimliliğin parametre-eşleşmeli koşulda da sağlam olup olmadığını test etmek için Düz Kronecker’i Yoğun MLP’nin parametre sayısını aşana kadar derinleştirdik.

Table 5: Basit kompozisyonel görevde parametre-eşleşmeli karşılaştırma. Derin Düz Kronecker, daha fazla parametreyle bile çöker.

| Model                       | Parametre | Test Doğruluğu |
|-----------------------------|-----------|----------------|
| Yoğun MLP ( $h = 128$ )     | 20,868    | 0.798          |
| Düz Kronecker ( $K = 3$ )   | 2,564     | 0.801          |
| Düz Kronecker ( $K = 16$ )  | 4,356     | 0.402          |
| Düz Kronecker ( $K = 168$ ) | 21,764    | 0.257          |

**Bulgu.** Yoğun MLP’nin parametre sayısını eşleştirmek için  $K = 168$  katman gerekir; bu noktada Düz Kronecker’ın doğruluğu 0.257’ye düşer — rastgeleden ( $1/4 = 0.25$ ) daha kötü. Çöküş yapısaldır: normalizasyon olmadan tekrarlanan bilinear + SiLU bilgiyi yok eder.  $8\times$  verimlilik iddiası bu nedenle *kullanışlı rejim* ( $K \leq 3$ ) hakkında bir ifadedir, evrensel bir özellik değil.

## 4.6 Örtük Düzenleştirme Hipotezi

Görev-uygunluk hipotezi (Bölüm 3.3), “Kronecker mimarileri görevin yapısı tensör faktörizasyonu ile uyumlu olduğunda verimlidir” şeklinde formüle edilmişti. Bunu altı görevde test ettik (rastgele lineer, permüte MNIST, gürültülü MNIST, blok kompozisyonel, grid korelasyonlu, Fashion-MNIST) ve tahminin *ters yönde* çıktığını gördük: otokorelasyon, Kronecker’ın kazanma oranıyla *negatif* korelasyon gösteriyor ( $r = -0.38$ ,  $p = 0.46$ ).

Sonraki bir ablasyon farklı bir mekanizmayı ortaya çıkardı: *gürültü seviyesi* Kronecker’ın avantajını öngörüyor ( $r = +0.95$ ,  $p = 0.012$ ). Tablo ?? özetler.

Table 6: Blok kompozisyonel görevde gürültü ablasyonu (20 tohum). Kronecker’ın parametre kısıtı örtük düzenleştirici olarak çalışır.

| Gürültü | Yoğun MLP         | Düz Kronecker     | Düz Kazanma |
|---------|-------------------|-------------------|-------------|
| 0.00    | $0.980 \pm 0.006$ | $0.945 \pm 0.014$ | 0/20        |
| 0.10    | $0.913 \pm 0.011$ | $0.893 \pm 0.011$ | 1/20        |
| 0.30    | $0.819 \pm 0.020$ | $0.822 \pm 0.012$ | 11/20       |
| 0.50    | $0.734 \pm 0.023$ | $0.759 \pm 0.017$ | 18/20       |
| 0.60    | $0.667 \pm 0.026$ | $0.705 \pm 0.018$ | 18/20       |

**Gözden geçirilmiş hipotez.** Kronecker’ın  $2n^2$  parametre kısıtı, mimari düzeyde bir düzenleştirici işlevi görür. Temiz veride ifade gücünü sınırlar ve Yoğun MLP’ye kaybeder; gürültülü veride overfitting’i önler ve kazanır. Geçiş noktası gürültü  $\approx 0.30$ ’dur.

Bu yeniden formülasyon önceki gözlemi kapsar ve *mekanistik* bir açıklama sunar: kazanç yapısal uyumdan değil, örtük düzenleştirmeden gelir.

## 4.7 Negatif Sonuçlar

Kronecker iddiasını sınırlayan iki negatif sonucu belgeliyoruz.

**Parametre-eşleşmeli karşılaştırma.** Rastgele lineer görevde, her iki mimariye aynı parametre bütçesi ( $\sim 21,764$ ) verildiğinde, Yoğun MLP 0.900’a ulaşırken, Düz Kronecker  $K = 168$  derinliğinde 0.257’de kalır. Derin düz zincirler çöker: normalizasyon olmadan tekrarlanan bilinear + SiLU bilgiyi yok eder. Hiyerarşik Kronecker kısmen çöküşten kaçınır (0.816) ama yine de Yoğun MLP’ye kaybeder.

**LayerNorm + residual.** Düz Kronecker’a LayerNorm ve artık bağlantılar eklemek 0.402’den 0.584’e iyileştirir, ama hiyerarşik (0.817) veya yoğun (0.916) seviyesine ulaşmaz. Düz zincirin sınırlamasının yalnızca normalizasyon sorunu olmadığı sonucuna varıyoruz.

Bu sonuçlar, Kronecker avantajının *görev-koşullu* olduğunu, evrensel olmadığını ortaya koyar.

## 5 Tartışma

### 5.1 İstatistiksel Metodoloji

Bu çalışmada bildirilen tüm  $p$ -değerleri eşleşmiş tohumlarda eşleşmiş  $t$ -testlerinden elde edilmiştir. Aynı görev üzerinde birden fazla hipotez test edildiğinde (görev başına üç ikili karşılaştırma),  $\alpha = 0.05$  düzeyinde Bonferroni düzeltmesi anlamlılık için  $p < 0.017$  gerektirir. Bu ölçüt altında: görüntü kompozisyonel görevinde düz vs. yoğun ( $p = 0.0003$ ), düz vs. hiyerarşik ( $p < 0.0001$ ) ve yoğun vs. hiyerarşik ( $p < 0.0001$ ) hepsi anlamlı kalır. Basit kompozisyonel görevde bir anlamsız karşılaştırma ( $p = 0.52$ ) ve bir anlamlı (düz vs. hiyerarşik,  $p = 0.0008$ ) vardır.

### 5.2 Ne Zaman Hangisi?

Deneylerimiz basit bir karar kuralı verir:

1. **Metrik seçimi.** Mümkünse lineer metrikler (doğruluk, bit-doğruluğu) kullanın; kazanç formülü kapalı-formdur (Denklem 1). Makro  $F_1$  için sınıf-başına ağırlıklı özdeşliği kullanın.
2. **Mimari seçimi.** Mimariyi görev yapısına uydurun. Rastgele lineer görevler Yoğun MLP’yi tercih eder; blok-yapılı görevler Düz Kronecker’ı tercih eder; uzamsal korelasyonlu görüntü-benzeri görevler Hiyerarşik Kronecker’ı tercih eder.
3. **Hiyerarşi.** Uzamsal yapısı olmayan görevlerde hiyerarşik Kronecker’ı kullanmayın:  $34\times$  daha fazla parametreye mal olur ve düşük performans verir.

### 5.3 $F_1$ Formülü Neden Sınıf-Başına Ağırlık Gerektirir?

Lineer metrikler için ağırlık kapsama indirgenir:  $\sum_c D_c = 2N$  özdeş olarak, yani  $w =$  kapsam. Makro  $F_1$  için sınıf-başına ağırlıklar  $w_c = D_s^c / (D_s^c + D_n^c)$  sınıflar arasında ve kapsam’dan farklıdır; doğru toplama kaçınılmaz olarak sınıf-başındır.

### 5.4 Yapısal Uyum İlkesi

Kronecker sonuçları daha geniş bir ilke önerir: *bir parametre bütçesi, örtük kısıtları görevin bağımlılıklarıyla uyumlu olduğunda en verimli şekilde harcanır.* Bir bilinear katman operatörü  $B^\top \otimes A$  formuna kısıtlar. Görevin hedefi bu forma uyduğunda kısıt bedavadır; uymadığında kısıt darboğaza dönüşür.

## 6 Sınırlar ve Gelecek Çalışma

**Sınırlar.** Kronecker görev-uygunluk çalışması üç sentetik görev tipini kapsıyor; gerçek dünya görüntü veya dil verisine genelleme açık bir sorudur. Sınıf-başına  $F_1$  özdeşliği makro  $F_1$  için ispatlanmıştır; ağırlıklı ve mikro varyantlar ele alınmamıştır. Sinirsel temellerimiz sıfırdan eğitilen küçük modellerdir; ön-eğitilmiş dil modelleriyle karşılaştırma yapmıyoruz. İstatistiksel güç yeterlidir ( $n = 20-50$ ) ama kapsamlı değildir.

**Gelecek çalışma.** (1) Kronecker hipotezini doğal görüntü ve metin üzerinde test edin. (2) Ağırlıklı  $F_1$ , kesinlik ve duyarlılık için sınıf-başına özdeşlikler türetin. (3) Hibrit formülü ön-eğitilmiş büyük modellere genişletin. (4) Görev-uygunluğun yalnızca veri istatistiklerinden öngörülüp öngörülemediğini araştırın.

## 7 Sonuç

Hibrit sistemler koşulsuz kazanmaz. Kazançları üç bağımsız boyuta bağlıdır: metrik tipi (lineer ve lineer olmayan), mimari tipi (Kronecker ve yoğun) ve görev yapısı (rastgele ve kompozisyonel). Her boyut için bir formül, mimari seçimi için istatistiksel kanıt ve geometrik mimarinin ne zaman kaybettiğine dair dürüst bir açıklama sunuyoruz. Birlikte, bu sonuçlar hibrit sistem tasarımının sezgisel değil ilkel yapılabileceğini öne sürer.

## Yeniden Üretilirlik Beyanı

Tüm deneyler halka açık depodan [github.com/arreasonn-jpg/hiper\\_geometrik\\_ai](https://github.com/arreasonn-jpg/hiper_geometrik_ai) yeniden üretilebilir. Tohumlar ve hiperparametreler yukarıda listelenen betiklerde sabittir. MNIST veri kümesi standart Google Cloud yansısından otomatik indirilir. Ön-eğitilmiş model kullanılmamıştır.

## References

- [1] E. Esa. Hibrit sembolik-sinirsel paradigma: Sinirsel temellere karşı kazancı öngören evrensel bir formül. *arXiv preprint*, 2026.
- [2] A. d’Avila Garcez ve L. C. Lamb. Neurosymbolic AI: The 3rd wave. *Artificial Intelligence Review*, 2023.
- [3] R. Manhaeve ve ark. DeepProbLog: Neural probabilistic logic programming. *NeurIPS*, 2018.
- [4] J. Nivre ve ark. Universal Dependencies v2. *LREC*, 2020.
- [5] A. Vaswani ve ark. Attention is all you need. *NeurIPS*, 2017.
- [6] T. R. Besold ve ark. Neural-symbolic learning and reasoning: A survey and interpretation. *arXiv preprint arXiv:1711.03902*, 2017.
- [7] J. Andreas, M. Rohrbach, T. Darrell ve D. Klein. Neural module networks. *CVPR*, 2016.
- [8] J. Johnson ve ark. CLEVR: A diagnostic dataset for compositional language and elementary visual reasoning. *CVPR*, 2017.
- [9] J. Mao ve ark. The neuro-symbolic concept learner: Interpreting scenes, words, and sentences from natural supervision. *ICLR*, 2019.
- [10] I. Tolstikhin ve ark. MLP-Mixer: An all-MLP architecture for vision. *NeurIPS*, 2021.

- [11] H. Liu ve ark. Pay attention to MLPs. *NeurIPS*, 2021.
- [12] A. Trockman ve J. Z. Kolter. Patches are all you need? *TMLR*, 2023.
- [13] A. Novikov, D. Podoprikin, A. Osokin ve D. Vetrov. Tensorizing neural networks. *NeurIPS*, 2015.
- [14] E. J. Hu ve ark. LoRA: Low-rank adaptation of large language models. *ICLR*, 2022.
- [15] A. Dosovitskiy ve ark. An image is worth 16x16 words: Transformers for image recognition at scale. *ICLR*, 2021.
- [16] G. Eryiğit. ITU Turkish NLP web service. *EACL*, 2014.
- [17] M. Sokolova ve G. Lapalme. A systematic analysis of performance measures for classification tasks. *Information Processing & Management*, 45(4):427–437, 2009.
- [18] J. Opitz ve S. Burst. Macro F1 and macro F1. *arXiv preprint arXiv:1911.03347*, 2019.
- [19] M. Grandini, E. Bagli ve G. Visani. Metrics for multi-class classification: An overview. *arXiv preprint arXiv:2008.05756*, 2020.
- [20] Y. Benjamini ve Y. Hochberg. Controlling the false discovery rate. *JRSS-B*, 57(1):289–300, 1995.
- [21] J. Cohen. *Statistical Power Analysis for the Behavioral Sciences*. Lawrence Erlbaum Associates, 2. baskı, 1988.