

Göreve Uygun Hibrit Mimariler: Metrik, Mimari ve Görev Boyutlarında Birleşik Bir Kazanç Teorisi

Erdem Esa
Bağımsız Araştırmacı

September 24, 2026

Abstract

Hibrit sistemler koşulsuz kazanmaz: kazançları metrik tipine, mimari tipine ve görev yapısına bağlıdır. Lineer metrikler için kesin bir özdeşlik ve makro F_1 için sınıf-başına bir genişletme sunuyoruz; lineer ağırlık lineer olmayan metriklerde çökmediği için bu genişletmenin zorunlu olduğunu gösteriyoruz. Ayrıca Kronecker mimarilerinin kompozisyonel ve gerçek görüntü görevlerinde $8\times-12.6\times$ daha parametre-verimli olduğunu, hiyerarşik varyansın ise görüntü-benzeri girdilerde istatistiksel olarak üstün olduğunu gösteriyoruz (50 tohum, $p < 0.0001$). Bu sonuçlar hibrit sistem tasarımının ilkeli olabileceğini öne sürüyor: metrikler için formül-güdümlü, görevler için yapı-güdümlü.

1 Giriş

Sembolik akıl yürütme ile sinirsel öğrenmeyi birleştiren hibrit sistemler modern yapay zeka araştırmalarının merkezinde yer alıyor. Ancak bir hibrit sistemin *ne zaman* sinirsel temelini geçtiği sorusu büyük ölçüde sezgisel kalmıştır. Önceki çalışmalar deneysel kılavuzlar önermiş, ama birleşik bir öngörü çerçevesi sunmamıştır.

Önceki çalışmamız [1], bir hibrit sembolik-sinirsel sistemin sinirsel temele karşı kazancı için, lineer metriklerde geçerli kapalı-form bir formül ortaya koydu:

$$\text{kazanç} = \text{kapsam}_{\text{sem}} \cdot (\text{doğruluk}_s - \text{doğruluk}_n), \quad (1)$$

burada $\text{kapsam}_{\text{sem}}$ sembolik kolun kapsamı, doğruluk_s ve doğruluk_n ise sembolik ve sinirsel doğruluklardır. Bu formül 12 dil, 4 görev tipi ve 2 metrik üzerinde ortalama 0.002 öngörü hatasıyla doğrulanmıştır.

Bu çalışma, lineer formülün kapsamadığı üç açık soruyu ele alır:

1. **Metrik kapsamı.** Formül, F_1 gibi lineer olmayan metriklere genellenebilir mi?
2. **Mimari seçimi.** Bilinear Kronecker mimarisi ne zaman standart yoğun MLP'ye tercih edilir?
3. **Görev yapısı.** Kazanç, görevin rastgele-lineer mi yoksa kompozisyonel mi olmasına nasıl bağlıdır?

Katkılar.

1. Lineer formülü, makro F_1 için *kesin* olan sınıf-başına bir özdeşliğe genişletiyoruz (Bölüm 2.2).

2. Kronecker mimarisinin kompozisyonel görevlerde $8\times$ daha parametre-verimli olduğunu ve hiyerarşik Kronecker'ın görüntü-benzeri kompozisyonel görevlerde yoğun MLP'yi istatistiksel olarak yendiğini gösteriyoruz (Bölüm 2.3).
3. Görev tipini mimari seçimine eşleyen bir karar ağacı sunuyoruz, 20–50 tohumlu eşleşmiş t -testleriyle desteklenmiş.
4. Negatif sonuçları dürüstçe belgeliyoruz (Bölümler 3.4 ve 4).

Terminoloji. Metin boyunca üç iddia düzeyi ayırt edilir: *kesin özdeşlik* (matematiksel olarak ispatlı, örn. Denklemler 2, ??), *öngörü formülü* (deneysel olarak doğrulanmış yaklaşıklık, örn. Denklem 1) ve *hipotez* (test edilmiş ama ispatlanmamış, örn. Bölüm 2.3).

2 Teori

2.1 Lineer Metrik Formülü

$s(x) \in \{0, 1, \perp\}$ sembolik kolun çıktısı olsun; $\perp$ çekimsizliği belirtir. $n(x) \in \{0, 1\}$ ise sinirsel kolun çıktısıdır. Hibrit kural: $h(x) = s(x)$ eğer $s(x) \neq \perp$, aksi halde $n(x)$.

Kapsam $\text{kapsam} = \Pr[s(x) \neq \perp]$ ve $\text{doğ}_n^\perp = \Pr[n(x) = y \mid s(x) = \perp]$ tanımlanır. Öge-bazlı doğruluk göstergesinde *lineer* olan herhangi bir M metriği için, hibritin değeri tam olarak ayrışır:

$$M_h = \text{kapsam} \cdot M_s + (1 - \text{kapsam}) \cdot M_n^\perp. \quad (2)$$

$M_n = \text{kapsam} \cdot M_n + (1 - \text{kapsam}) \cdot M_n$ teleskopik özdeşliğini çıkararak kazanç formülünü elde ederiz:

$$\text{kazanç} = \text{kapsam} \cdot (M_s - M_n) + (1 - \text{kapsam}) \cdot (M_n^\perp - M_n). \quad (3)$$

$M_n^\perp \approx M_n$ olduğunda ikinci terim ihmal edilir; artık hata $\varepsilon = (1 - \text{kapsam}) \cdot |M_n^\perp - M_n|$ ile sınırlıdır.

2.2 F_1 Sınıf-Başına Formülü

F_1 harmonik ortalama içerdiği için lineer değildir; lineer formül F_1 'de bozulur. Tek-etiketli sınıflandırmada *kesin* ayrışım:

$$F_1^h = \frac{1}{K} \sum_{c=1}^K [w_c \cdot F_{1s}^c + (1 - w_c) \cdot F_{1n}^c], \quad (4)$$

burada sınıf-başına ağırlık

$$w_c = \frac{D_s^c}{D_s^c + D_n^c}, \quad D_k^c = 2 \cdot \text{TP}_k^c + \text{FP}_k^c + \text{FN}_k^c. \quad (5)$$

Kritik gözlem: $w_c \neq \text{kapsam}$; sınıf-başına ağırlıklar sınıf dağılımına bağlıdır. Bu, lineer formülün F_1 'de neden bozulduğunu kesin olarak açıklar.

Neden önemli. Denklem ?? F_1 tanımının cebirsel bir sonucu olsa da, *öngörü* içeriği önemsiz değildir: sınıf-başına ağırlıklar w^c sınıflar arasında değişir (NER deneylerimizde deneysel olarak 0.37–0.66 aralığında), lineer formül ise tek bir ağırlık kapsam varsayar. Bu nedenle özdeşlik, lineer formülün hatasının neden büyük olduğunu ($\varepsilon \approx 0.019$) açıklar ve yapıcı bir çözüm sunar.

2.3 Kronecker Görev-Uygunluk

Bilinear Kronecker katmanı $Y = AXB$ hesaplar, $X \in \mathbb{R}^{n \times n}$ için. Düzleştirilmiş biçimde $Y_{\text{vec}} = (B^\top \otimes A)X_{\text{vec}}$, $n^2 \times n^2$ boyutlu bir lineer operatördür ve yalnızca $2n^2$ eğitilebilir parametreyle temsil edilir. Operatörün rankı $\text{rank}(A) \cdot \text{rank}(B) = n^2$ (tam rank), ama serbestlik derecesi $2n^2$ olarak kalır.

Bu yapısal kısıt, görevin kendi yapısı tensör ayrışımıyla uyumlu olduğunda bir *özellik* haline gelir:

Görev-Uygunluk Hipotezi. Kronecker mimarileri, görevin fonksiyonel bağımlılıkları $X \mapsto AXB$ tensör faktörizasyonuna uyduğunda parametre-verimlidir. Tersine, hedefi genel (faktörize edilemez) bir lineer dönüşüm olan görevlerde aynı kısıt bir darboğaza dönüşür.

Bu hipotezi Bölüm 3'te üç görev tipinde test ediyoruz.

3 Deneyler

3.1 Lineer Metrik Doğrulaması

Denklem 1, 8 dil ailesine yayılmış 12 veri kümesinde, 4 yazı sisteminde (Latin, Han, Kiril, Arap) ve 4 görev tipinde (ikili bağımlılık doğrulaması, çok-sınıflı, çok-etiketli, NER) doğrulandı. Tablo 1 toplu hatayı özetler.

Table 1: Lineer metrik formülü doğrulaması. Tüm konfigürasyonlarda ortalama öngörü hatası.

Boyut	Kapsam
Diller	12 (8 aile)
Yazı sistemleri	4 (Latin, Han, Kiril, Arap)
Görev tipleri	4 (ikili, çok-sınıflı, çok-etiketli, NER)
Metrikler	2 (doğruluk, bit-doğruluğu)
Ortalama hata	0.002
Maksimum hata	0.008

Sembolik gürültü altında (%0–%50), formülün öngörü hatası $\varepsilon = 0.0066$ değerinde değişmeden kalır; bu, lineer özdeşliğin hibrit topluluğun yapısal bir özelliğini yakaladığını gösterir.

3.2 F_1 Sınıf-Başına Doğrulaması

Lineer formül F_1 'de başarısız olur; çünkü F_1 harmonik ortalama içerir ve öge-bazlı doğruluk göstergesinde lineer değildir. Bunu 20 NER konfigürasyonunda (5 tohum $\times$ 4 gizli oran) test ettik.

Table 2: 20 NER konfigürasyonunda F_1 formül karşılaştırması. Lineer formül ağırlık olarak kapsam kullanır; sınıf-başına formül $w_c = D_s^c / (D_s^c + D_n^c)$ kullanır.

Formül	Ortalama ε	Maksimum ε
Lineer (kapsam-ağırlıklı)	0.0188	0.0515
Sınıf-başına (w_c -ağırlıklı)	0.000000	0.000000

Sınıf-başına formül 20 konfigürasyonun tümünde makine hassasiyetinde hata verir; bu, genişletmenin makro F_1 için kesin olduğunu doğrular.

3.3 Kronecker Görev-Uygunluk Sonuçları

Görev-uygunluk hipotezini üç görev tipinde test ettik: rastgele lineer öğretmen (sentetik), basit kompozisyonel görev (blok güçleri) ve görüntü-benzeri kompozisyonel görev (uzamsal korelasyonlu 2D grid). Tablo 3 her durumda kazanımı özetler.

Table 3: Görev tipine göre kazanan. Parametre sayıları parantez içindedir. İstatistiksel testler: eşleşmiş tohumlarda t -testi.

Görev tipi	Kazanan	Test Doğ.	Verimlilik
Rastgele lineer	Yoğun MLP	—	temel
Basit kompozisyonel	Düz Kronecker	0.8007	$8\times$ az
Görüntü kompozisyonel	Hiy. Kronecker	0.8360	$34\times$ fazla

Basit kompozisyonel. 20 tohum. Düz Kronecker (2,564 parametre) 0.8007 ± 0.0202 sonucuna ulaşırken, Yoğun MLP (20,868 parametre) 0.7982 ± 0.0190 elde ediyor; fark anlamlı değil ($p = 0.52$). Hiyerarşik Kronecker (87,044 parametre) 0.7872 'ye ulaşır ve düzden *anlamlı olarak daha kötüdür* ($p = 0.0008$, Cohen $d = -0.75$).

Görüntü kompozisyonel. 50 tohum. Hiyerarşik Kronecker 0.8360 ± 0.0217 sonucuna ulaşırken, Yoğun MLP 0.8190 ± 0.0198 (eşleşmiş t -testi: $p < 0.0001$, Cohen $d = -1.37$). Düz Kronecker (2,564 parametre) 0.8267 'ye ulaşır ve Yoğun MLP'den anlamlı olarak iyidir ($p = 0.0003$, $d = +0.51$); bu, $8\times$ parametre verimliliğini küçük bir mutlak doğruluk avantajıyla gösterir.

İki kompozisyonel görev arasındaki karşıtlık—basit bloklar ve uzamsal korelasyonlu görüntü-benzeri gridler—Kronecker'ın avantajının görev ile tensör faktörizasyonu arasındaki *yapısal uyumun derecesine* bağlı olduğunu gösterir.

3.4 Gerçek Görüntü Doğrulaması (MNIST)

Görev-uygunluk hipotezinin sentetik gridlerin ötesine geçip geçmediğini test etmek için MNIST (28×28 gri-ton rakamlar) üzerinde değerlendirdik. 2000 örnekle eğitip 500 örnekle 30 epoch boyunca test ettik.

Table 4: MNIST sonuçları (5 tohum). Düz Kronecker, en büyük Yoğun MLP'den $12.6\times$ daha az parametreyle rekabetçi doğruluğa ulaşır.

Model	Parametre	Test Doğruluğu
Yoğun MLP ($h = 32$)	26,506	0.594 ± 0.056
Yoğun MLP ($h = 128$)	118,282	0.808 ± 0.017
Düz Kronecker ($K = 1$)	9,418	0.770 ± 0.013
Düz Kronecker ($K = 2$)	10,986	0.717 ± 0.041
Düz Kronecker ($K = 3$)	12,554	0.662 ± 0.048

Bulgular. (1) *Parametre verimliliği gerçek görüntülere de uzanır:* Düz Kronecker (9,418 param) 0.770 'a ulaşırken, Yoğun MLP (118,282 param) 0.808 'de kalır — $12.6\times$ azaltma, %3.8 doğruluk farkıyla. (2) *Derinlik çöküşü evrenseldir:* hem sentetik hem gerçek veride $K = 1$ en iyidir, $K > 1$ daha kötüdür. Bu, çöküşün yapısal olduğunu doğrular. (3) *Yapısal kısıt düzenleştiricidir:* Yoğun MLP $h = 32$ (26,506 param) Düz Kronecker'ın 9,418 parametreliliğinden daha kötü performans verir; bu Kronecker kısıtının örtük bir düzenleştirici olduğunu öne sürer.

Dürüst sınırlar. Mutlak doğruluk farkı (%3.8) devam ediyor. Kronecker verimlidir, baskın değil.

3.5 Negatif Sonuçlar

Kronecker iddiasını sınırlayan iki negatif sonucu belgeliyoruz.

Parametre-eşleşmeli karşılaştırma. Rastgele lineer görevde, her iki mimariye aynı parametre bütçesi ($\sim 21,764$) verildiğinde, Yoğun MLP 0.900’a ulaşırken, Düz Kronecker $K = 168$ derinliğinde 0.257’de kalır. Derin düz zincirler çöker: normalizasyon olmadan tekrarlanan bilinear + SiLU bilgiyi yok eder. Hiyerarşik Kronecker kısmen çöküşten kaçınır (0.816) ama yine de Yoğun MLP’ye kaybeder.

LayerNorm + residual. Düz Kronecker’a LayerNorm ve artık bağlantılar eklemek 0.402’den 0.584’e iyileştirir, ama hiyerarşik (0.817) veya yoğun (0.916) seviyesine ulaşmaz. Düz zincirin sınırlamasının yalnızca normalizasyon sorunu olmadığı sonucuna varıyoruz.

Bu sonuçlar, Kronecker avantajının *görev-kışullu* olduğunu, evrensel olmadığını ortaya koyar.

4 Tartışma

4.1 İstatistiksel Metodoloji

Bu çalışmada bildirilen tüm p -değerleri eşleşmiş tohumlarda eşleşmiş t -testlerinden elde edilmiştir. Aynı görev üzerinde birden fazla hipotez test edildiğinde (görev başına üç ikili karşılaştırma), $\alpha = 0.05$ düzeyinde Bonferroni düzeltmesi anlamlılık için $p < 0.017$ gerektirir. Bu ölçüt altında: görüntü kompozisyonel görevinde düz vs. yoğun ($p = 0.0003$), düz vs. hiyerarşik ($p < 0.0001$) ve yoğun vs. hiyerarşik ($p < 0.0001$) hepsi anlamlı kalır. Basit kompozisyonel görevde bir anlamsız karşılaştırma ($p = 0.52$) ve bir anlamlı (düz vs. hiyerarşik, $p = 0.0008$) vardır.

4.2 Ne Zaman Hangisi?

Deneylerimiz basit bir karar kuralı verir:

1. **Metrik seçimi.** Mümkünse lineer metrikler (doğruluk, bit-doğruluğu) kullanın; kazanç formülü kapalı-formdur (Denklem 1). Makro F_1 için sınıf-başına ağırlıklı özdeşliği kullanın.
2. **Mimari seçimi.** Mimariyi görev yapısına uydurun. Rastgele lineer görevler Yoğun MLP’yi tercih eder; blok-yapılı görevler Düz Kronecker’ı tercih eder; uzamsal korelasyonlu görüntü-benzeri görevler Hiyerarşik Kronecker’ı tercih eder.
3. **Hiyerarşi.** Uzamsal yapısı olmayan görevlerde hiyerarşik Kronecker’ı kullanmayın: $34\times$ daha fazla parametreye mal olur ve düşük performans verir.

4.3 F_1 Formülü Neden Sınıf-Başına Ağırlık Gerektirir?

Lineer metrikler için ağırlık kapsama indirgenir: $\sum_c D_c = 2N$ özdeş olarak, yani $w =$ kapsam. Makro F_1 için sınıf-başına ağırlıklar $w_c = D_s^c / (D_s^c + D_n^c)$ sınıflar arasında ve kapsam’dan farklıdır; doğru toplama kaçınılmaz olarak sınıf-başınadır.

4.4 Yapısal Uyum İlkesi

Kronecker sonuçları daha geniş bir ilke önerir: *bir parametre bütçesi, örtük kısıtları görevin bağımlılıklarıyla uyumlu olduğunda en verimli şekilde harcanır*. Bir bilinear katman operatörü $B^\top \otimes A$ formuna kısıtlar. Görevin hedefi bu forma uyduğunda kısıt bedavadır; uymadığında kısıt darboğaza dönüşür.

5 Sınırlar ve Gelecek Çalışma

Sınırlar. Kronecker görev-uygunluk çalışması üç sentetik görev tipini kapsıyor; gerçek dünya görüntü veya dil verisine genelleme açık bir sorudur. Sınıf-başına F_1 özdeşliği makro F_1 için ispatlanmıştır; ağırlıklı ve mikro varyantlar ele alınmamıştır. Sinirsel temellerimiz sıfırdan eğitilen küçük modellerdir; ön-eğitilmiş dil modelleriyle karşılaştırma yapmıyoruz. İstatistiksel güç yeterlidir ($n = 20\text{--}50$) ama kapsamlı değildir.

Gelecek çalışma. (1) Kronecker hipotezini doğal görüntü ve metin üzerinde test edin. (2) Ağırlıklı F_1 , kesinlik ve duyarlılık için sınıf-başına özdeşlikler türetin. (3) Hibrit formülü ön-eğitilmiş büyük modellere genişletin. (4) Görev-uygunluğun yalnızca veri istatistiklerinden öngörülüp öngörülemediğini araştırın.

6 Sonuç

Hibrit sistemler koşulsuz kazanmaz. Kazançları üç bağımsız boyuta bağlıdır: metrik tipi (lineer ve lineer olmayan), mimari tipi (Kronecker ve yoğun) ve görev yapısı (rastgele ve kompozisyonel). Her boyut için bir formül, mimari seçimi için istatistiksel kanıt ve geometrik mimarinin ne zaman kaybettiğine dair dürüst bir açıklama sunuyoruz. Birlikte, bu sonuçlar hibrit sistem tasarımının sezgisel değil ilkel yapılabileceğini öne sürer.

References

- [1] E. Esa. Hibrit sembolik-sinirsel paradigma: Sinirsel temellere karşı kazancı öngören evrensel bir formül. *arXiv preprint*, 2026.
- [2] A. d’Avila Garcez ve L. C. Lamb. Neurosymbolic AI: The 3rd wave. *Artificial Intelligence Review*, 2023.
- [3] R. Manhaeve ve ark. DeepProbLog: Neural probabilistic logic programming. *NeurIPS*, 2018.
- [4] J. Nivre ve ark. Universal Dependencies v2. *LREC*, 2020.
- [5] A. Vaswani ve ark. Attention is all you need. *NeurIPS*, 2017.