

Kronecker Mimarilerinde Örtük Düzenleştirme: Yapısal Kısıtlar Ne Zaman Yardımcı Olur?

Erdem Esa
Bağımsız Araştırmacı

September 24, 2026

Abstract

Kronecker mimarilerinin değeri geleneksel olarak *yapısal uyum* ile açıklanır: görevin fonksiyonel bağımlılıkları tensör faktörizasyonu ile eşleştğinde parametre verimliliği. Bu açıklamanın *yanlış* olduğunu gösteriyoruz. Altı görevde otokorelasyon ve Kronecker kazanma oranı *negatif* korelasyon gösteriyor ($r = -0.38$). Bunun yerine, Kronecker’ın parametre kısıtının ($n^2 \times n^2$ operatör için $2n^2$ parametre) bir *örtük düzenleştirici* olarak çalıştığını öne sürüyoruz. Beş gürültü seviyesi ve 20 tohumda, gürültü Kronecker’ın avantajını $r = +0.95$, $p = 0.012$ ile öngörüyor. Grid yapısı gerekli ama yeterli değil: bir graf görevinde avantaj tamamen kayboluyor ve tam-bilinear bir görevde ($Y = AXB$ — Kronecker’ın doğal olarak temsil ettiği form), Düz Kronecker yalnızca 1/20 tohumda kazanıyor. Darboğaz ifade gücü değil, optimizasyondur. Bulgularımız mimari tasarımda bir prensip öneriyor: parametre bütçesini görevin düzenleştirme ihtiyacıyla eşleştirin.

1 Giriş

Ağırlık matrislerini faktörize eden parametre-verimli mimariler — Tensor Train [2], LoRA [3] ve bilinear Kronecker katmanları [4] — rutin olarak *yapısal uyum* iddiasıyla gerekçelendirilir: faktörize bir temsilin belirli görevlerin içsel yapısıyla eşleştiği ve bu nedenle daha az parametreyle karşılaştırılabilir doğruluk elde ettiği iddiası.

Ancak bu açıklama nadiren doğrudan test edilir. Kendi önceki çalışmamızda [1] bir “görev-uygunluk hipotezi” önermiştik: Kronecker mimarileri, görevin bağımlılıkları $X \mapsto AXB$ tensör faktörizasyonuna uyduğunda verimli olmalı. Hipotez makuldü, gözlenen veriyle tutarlıydı ve hiçbir zaman resmen çürütülmemişti.

Bu çalışma onu doğrudan teste tabi tutar.

Katkılar.

- İki rakip hipotezi formüle ediyoruz: *yapısal uyum* (H1) ve *örtük düzenleştirme* (H2), ve bunların aynı görev kümesinde *zıt* tahminler ürettiğini gösteriyoruz (Bölüm 2).
- H1’i altı görevde reddediyoruz: otokorelasyon, Kronecker’ın kazanma oranıyla *negatif* korelasyon gösteriyor ($r = -0.38$, $p = 0.46$; Bölüm 3.1).
- H2’yi beş gürültü seviyesinde 20 tohumla doğruluyoruz: gürültü, Kronecker’ın kazanma oranıyla $r = +0.95$, $p = 0.012$ düzeyinde korelasyon gösteriyor (Bölüm 3.2).
- Sirküler tasarımı kontrol ediyoruz: bir graf görevinde avantaj kayboluyor ve tam-bilinear bir görevde ($Y = AXB$) Düz Kronecker yalnızca 1/20 tohumda kazanıyor. Darboğaz ifade gücü değil, optimizasyondur (Bölüm 3.3).

2 Teori

2.1 Kronecker Parametre Kısıtı

Bir bilinear Kronecker katmanı $X \in \mathbb{R}^{n \times n}$ için $Y = AXB$ hesaplar. Düzleştirilmiş biçimde, indüklenen lineer operatör $Y_{\text{vec}} = (B^T \otimes A)X_{\text{vec}}$, $n^2 \times n^2$ boyutunda, yalnızca $2n^2$ ağırlıkla parametrelendirilmiştir. Parametre azaltma oranı:

$$\frac{n^4}{2n^2} = \frac{n^2}{2}. \quad (1)$$

Bu kısıtın iki rakip sonucu vardır:

1. **İfade gücü kaybı:** bazı lineer operatörler temsil edilemez (özellikle CP-rankı n 'i aşanlar).
2. **Örtük düzenlileştirme:** efektif hipotez sınıfı daha küçüktür, bu overfitting'i önleyebilir.

Hangi sonucun baskın olduğu göreve bağlıdır.

2.2 İki Rakip Hipotez

H1: Yapısal Uyum. Bir Kronecker katmanı, görevin fonksiyonel bağımlılıkları $X \mapsto AXB$ tensör faktörizasyonuna uyduğunda parametre-verimlidir. *Öngörü:* yüksek grid yapılı görevler (yüksek uzamsal otokorelasyon) Kronecker'ı tercih eder.

H2: Örtük Düzenlileştirme. $2n^2$ parametre kısıtı mimari düzeyde bir düzenlileştirici işlevi görür. *Öngörü:* gürültülü görevler (overfitting'in baskın başarısızlık modu olduğu), Kronecker'ı tercih eder; temiz görevler Yoğun MLP'yi tercih eder.

İki hipotez aynı görevlerde *zıt* tahminler üretir:

- H1: otokorelasyon $\uparrow \Rightarrow$ Kronecker kazanır
- H2: gürültü $\uparrow \Rightarrow$ Kronecker kazanır

Her ikisini de Bölüm 3'te test ediyoruz.

3 Deneyler

Tüm deneylerde $K = 1$ derinliğinde bilinear Kronecker katmanı (bu görevler için optimal derinlik) ve gizli boyutu $n^2/4$ olan bir Yoğun MLP kullanıyoruz. Her ikisi de Adam ile 60–100 epoch (göreve bağlı) eğitilir, konfigürasyon başına 20 tohum.

3.1 H1 Testi: Yapısal Uyum

2D uzamsal otokorelasyonla ölçülen, değişen derecelerde grid yapısına sahip altı görev oluşturduk.

Otokorelasyon ile Kronecker kazanma oranı arasındaki Pearson korelasyonu: $r = -0.38$, $p = 0.46$ ($n=6$). **H1 reddedildi.**

3.2 H2 Testi: Örtük Düzenlileştirme

Görevi sabit tuttuk (ayarlanabilir gürültülü blok kompozisyonel) ve gürültü seviyesini beş değerde değiştirdik, her biri 20 tohum.

Gürültü seviyesi ile Kronecker kazanma oranı arasındaki Pearson korelasyonu: $r = +0.953$, $p = 0.012$ ($n=5$). **H2 doğrulandı.**

Geçiş noktası (%50 kazanma oranı) gürültü ≈ 0.30 'da gerçekleşir. Bu eşğin altında Yoğun MLP'nin tam ifade gücü baskındır; üstünde Kronecker'ın parametre kısıtı overfitting'i önler.

Table 1: H1 testi: otokorelasyon vs Kronecker kazanma oranı. İlişki *negatif*, H1 ile çelişiyor.

Görev	Otokorelasyon	Kronecker Kazanma
rastgele lineer	-0.01	1/20
permüte MNIST	+0.00	0/20
gürültülü MNIST	+0.23	9/20
basit blok	+0.80	0/20
grid korelasyonlu	+0.09	12/20
Fashion-MNIST	+0.87	0/20

Table 2: H2 testi: gürültü seviyesi vs Kronecker kazanma oranı. İlişki güçlü pozitif, H2’yi doğruluyor.

Gürültü	Yoğun MLP	Düz Kronecker	Kronecker Kazanma
0.00	0.980 ± 0.006	0.945 ± 0.014	0/20
0.10	0.913 ± 0.011	0.893 ± 0.011	1/20
0.30	0.819 ± 0.020	0.822 ± 0.012	11/20
0.50	0.734 ± 0.023	0.759 ± 0.017	18/20
0.60	0.667 ± 0.026	0.705 ± 0.018	18/20

3.3 Sirküler Mantık Kontrolü

Bölüm 3.1 ve 3.2’deki görevler grid yapılıdır. Kronecker’ın avantajının görev tasarımının bir yapaylığı olma olasılığını dışlamak için grid rejiminin dışında dört görev test ettik.

Table 3: Grid olmayan kontrol görevleri (20 tohum). Kronecker graf ve tam-bilinear görevlerde kaybeder.

Görev	Yoğun MLP	Düz Kronecker	Kronecker Kazanma
Grid temel	0.819	0.822	11/20
Dizi (1D)	0.745	0.780	18/20
Graf (grid yok)	0.821	0.609	0/20
Rastgele faktör ($Y = AXB$)	0.706	0.599	1/20

Graf görevi. Kronecker graf yapılı bir görevde %21 kaybediyor. Avantaj grid olmayan veriye geçmiyor.

Tam-bilinear görev. Rastgele faktör görevi *tam olarak* bir bilinear form $Y = AXB$ ’dir; Kronecker katmanı bunu doğal olarak temsil eder. Yine de Düz Kronecker yalnızca 1/20 tohumda kazanıyor. Bu, bir *optimizasyon*, ifade gücü değil, sınırlamasını izole eder: hedef fonksiyon Kronecker hipotez sınıfında olsa bile, birinci-mertebe gradyan inişi onu güvenilir biçimde bulamıyor.

Dizi görevi. 16×16 ’ya reshape edilmiş 1D dizi yapay 2D yapı kazanır; bu 18/20 kazanma oranını açıklar. Bu, grid gereksinimiyle tutarlıdır.

Birleşik hipotez. Kronecker mimarileri *iki* koşulu birlikte gerektirir: (i) girdide grid veya tensör yapısı, ve (ii) gürültülü veriden kaynaklanan düzenileştirme ihtiyacı. Hiçbiri tek başına yeterli değildir.

4 Tartışma

4.1 Mekanizma: Kronecker Neden Düzenleştirir?

Kronecker katmanı $2n^2$ parametreyle $n^2 \times n^2$ operatörü temsil eder; parametre azaltma oranı $n^2/2$ 'dir. Bu, ağır *efektif kapasitesini* sınırlar:

- **Yoğun MLP:** serbest ağırlıklar, herhangi bir lineer haritayı temsil edebilir $\Rightarrow$ overfitting riski yüksek
- **Kronecker:** faktörize yapı, “kolay” fonksiyonları öğrenir $\Rightarrow$ overfitting riski düşük

Bu, **Dropout** [6] (rastgele nöron kapatma) ve **Weight Decay** [5] (L2 cezası) ile aynı ailedendir: mimari düzeyde düzenleştirme.

4.2 İfade Gücü ve Optimizasyon Ayrımı

Beklenmedik bulgu (Bölüm 3.3): Rastgele faktör görevi *tam olarak* $Y = AXB$ formunda — Kronecker’ın temsil ettiği yapı. Ama Düz Kronecker 1/20 tohumda kazanıyor.

Yorum: Sorun ifade gücü değil, *optimizasyon yüzeyi*. Tek katmanlı bilinear + head, bu “kolay” görevi bile öğrenemiyor. Bu, teorik ifade gücü ile pratik öğrenilebilirlik arasındaki boşluğu gösterir ve düzenleştirme hipotezini güçlendirir: Kronecker’ın değeri, öğrenme kapasitesinden değil, kısıtlamasından gelir.

4.3 Pratik Kılavuz

Birleşik hipotezimiz (grid yapısı $\wedge$ gürültü) somut bir karar kuralı verir:

Table 4: Görev tipine göre mimari önerisi.

Görev tipi	Öneri
Gürültülü grid (görüntü, spektrogram, sensör)	Kronecker
Temiz grid (matematik tablolar, kesin veri)	Yoğun MLP
Graf (moleküler, sosyal, atıf)	Yoğun MLP veya GNN
Sıralı (metin, ses)	Transformer
Düşük-rank bilinear	LoRA veya Tensor Train

Özellikle rastgele faktör sonucu şunu önerir: bir görevin *bilindiği* bilinear olduğu durumda bile, Kronecker uygun mimari değildir — girdi aynı zamanda grid yapısına ve gürültüye sahip olmadıkça.

5 Sınırlar ve Gelecek Çalışma

Sınırlar. Tüm görevler sentetik veya küçük ölçeklidir (MNIST, Fashion-MNIST, 28×28 gridler). ImageNet, WikiText veya diğer büyük ölçekli kıyaslamalarda test yapmıyoruz. Yalnızca $K = 1$ derinliği değerlendirilir; daha derin Kronecker zincirlerinin, önceki çalışmada normalizasyon olmadan tekrarlanan bilinear + SiLU altında çıktığı gösterilmişti. “İki koşul” hipotezi yalnızca burada incelenen on görevde doğrulanmıştır. Düz Kronecker’ın tam-bilinear bir hedefi neden öğrenemediğine dair teorik bir analiz açık kalmaktadır.

Gelecek çalışma. (1) Hipotezi büyük ölçekli görüntü ve dil verisinde test edin. (2) Diğer faktörize mimarilere genişletin (Tensor Train, LoRA, CP ayrışımı). (3) Bilinear katmanların optimizasyon manzarasını teorik olarak analiz edin. (4) Veri istatistiklerinden, Kronecker düzenleştirmesinin yardımcı olup olmayacağını öngören bir görev-yapısı tanılaması geliştirin.

6 Sonuç

Kronecker mimarileri için geleneksel açıklamanın — faktörize katman ile görev arasındaki yapısal uyum — doğrudan testte hayatta kalmadığını gösterdik. Altı görevde uzamsal otokorelasyon, Kronecker’ın kazanma oranıyla *negatif* korelasyon gösteriyor.

Alternatif açıklama, *örtük düzenleştirme*, hayatta kalıyor: Kronecker parametre kısıtı mimari bir düzenleştirici işlevi görür ve avantajı tam olarak görev overfitting’in baskın başarısızlık modu olduğu kadar gürültülü olduğunda ortaya çıkar. Geçiş gürültü ≈ 0.30 ’da gerçekleşir ve korelasyon $r = +0.95$, $p = 0.012$ düzeyindedir.

Kontrol deneylerimiz sınırı netleştirir. Bir graf görevinde avantaj kaybolur; tam-bilinear bir görevde ($Y = AXB$, Kronecker’ın doğal olarak temsil ettiği hedef) avantaj yine gerçekleşmez, bu da ifade gücü değil, optimizasyon sınırlamasını izole eder. Grid yapısı gerekli ama yeterli değildir; gürültü birincil sürücüdür.

Bu bulgular bir mimari tasarım prensibi önerir: parametre bütçesini görevin düzenleştirme ihtiyacıyla eşleştirin. Gelecek çalışma bunu diğer faktörize mimarilere (Tensor Train, LoRA, CP ayrışımı) ve büyük ölçekli veriye genişletmelidir.

References

- [1] E. Esa. Göreve uygun hibrit mimariler: Metrik, mimari ve görev boyutlarında birleşik bir kazanç teorisi. *arXiv preprint*, 2026.
- [2] A. Novikov, D. Podoprikin, A. Osokin ve D. Vetrov. Tensorizing neural networks. *NeurIPS*, 2015.
- [3] E. J. Hu ve ark. LoRA: Low-rank adaptation of large language models. *ICLR*, 2022.
- [4] I. Tolstikhin ve ark. MLP-Mixer: An all-MLP architecture for vision. *NeurIPS*, 2021.
- [5] A. Krogh ve J. Hertz. A simple weight decay can improve generalization. *NeurIPS*, 1991.
- [6] N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever ve R. Salakhutdinov. Dropout: A simple way to prevent neural networks from overfitting. *JMLR*, 15(1):1929–1958, 2014.
- [7] T. Miyato, T. Kataoka, M. Koyama ve Y. Yoshida. Spectral normalization for generative adversarial networks. *ICLR*, 2018.
- [8] A. Vaswani ve ark. Attention is all you need. *NeurIPS*, 2017.