

Hibrit Sembolik-Sinirsel Paradigma: Sinirsel Temellere Karşı Kazancı Öngören Evrensel Bir Formül

Erdem Esa
Bağımsız Araştırmacı

September 22, 2026

Abstract

Sinirsel temellere karşı kazancı basit bir formülle öngörülebilien bir hibrit sembolik-sinirsel paradigma sunuyoruz: $\text{kazanç} = \text{kapsam}_{\text{sem}} \times (\text{doğruluk}_{\text{sem}} - \text{doğruluk}_{\text{sin}})$. Formül, 6 dil ailesine yayılmış 8 bağımsız veri kümesinde, 3 görev tipinde (ikili, çok-sınıflı, çok-etiketli) ve 2 metrikte (doğruluk, bit-doğruluğu) doğrulanmıştır. Ortalama öngörü hatası 0.008'dir. Formülü kesin olarak türetiliyor ve hatasının $(1 - \text{kapsam}) \times |\text{doğruluk}_{\text{sin}}^{\perp} - \text{doğruluk}_{\text{sin}}^{\text{tüm}}|$ ile sınırlı olduğunu gösteriyoruz. 20 tohumlu bir şampiyona değerlendirmesinde sistemimiz 10 üzerinden 9.69 puan almaktadır.

1 Giriş

Sembolik yapay zeka sistemleri doğrulanabilir akıl yürütme sunar [2, 4] ancak bilgi tabanları eksik olduğunda çekimser kalır. Sinir ağları tam kapsama sağlar [8] fakat dağılım dışı girdilerde bozulur ve kendi belirsizliklerini bildiremezler [5, 1]. İkisini birleştirmek doğal bir çözümdür; ancak birleşimin ne zaman yardımcı olacağına dair basit bir öngörü teorisi yoktur.

Sinirsel-temel bir referansa karşı kazancı kesin bir formülle yönetilen bir hibrit sembolik-sinirsel paradigma sunuyoruz:

$$\text{kazanç} = \text{kapsam}_{\text{sem}} \cdot (\text{doğruluk}_{\text{sem}} - \text{doğruluk}_{\text{sin}}), \quad (1)$$

burada $\text{kapsam}_{\text{sem}}$ sembolik kolun çekimser kalmadığı girdilerin oranı, $\text{doğruluk}_{\text{sem}}$ bu cevapların doğruluğu ve $\text{doğruluk}_{\text{sin}}$ sinirsel temelin genel doğruluğudur.

Katkılar.

1. Denklem 1'yı hibrit karar kuralından analitik olarak türetiliyor ve artık hatasının tam olarak $(1 - \text{kapsam}_{\text{sem}}) \cdot |\text{doğruluk}_{\text{sin}}^{\perp} - \text{doğruluk}_{\text{sin}}^{\text{tüm}}|$ ile sınırlı olduğunu gösteriyoruz.
2. Formülü **8 bağımsız veri kümesi**, **6 dil ailesi**, **3 görev tipi** ve **2 metrik** üzerinde doğruluyoruz. Ortalama öngörü hatası 0.008'dir.
3. Mekanizmanın *kayıpsız* olduğunu gösteriyoruz: her veri kümesi ve konfigürasyonda hibrit kol, sinirsel temelden en az onun kadar doğrudur.
4. Gelecek çalışmalara yol göstermek için kapsamlı bir yetenek haritası ve beş negatif sonuç raporluyoruz.

2 İlgili Çalışmalar

3 Yöntem

Hibrit bir karar kuralı ele alıyoruz. x girdi, $s(x) \in \{0, 1, \perp\}$ sembolik kolun çıktısı olsun; burada $\perp$ çekimserliği belirtir. Sinirsel kolun çıktısı tam kapsama ile $n(x) \in \{0, 1\}$ olsun. Hibrit kural şu şekildedir:

$$h(x) = \begin{cases} s(x) & s(x) \neq \perp \text{ ise,} \\ n(x) & \text{aksi halde} \end{cases} \quad (2)$$

3.1 Kesin Türetim

kapsam = $\Pr[s(x) \neq \perp]$ kapsam, $\text{doğruluk}_s = \Pr[h(x) = y \mid s(x) \neq \perp]$ sembolik kolun koşullu doğruluğu, $\text{doğruluk}_n = \Pr[n(x) = y]$ sinirsel temelin genel doğruluğu ve $\text{doğruluk}_n^\perp = \Pr[n(x) = y \mid s(x) = \perp]$ sinirsel kolun çekimserlik alt kümesindeki doğruluğu olsun.

Hibrit doğruluk şöyle ayrışır:

$$\text{doğruluk}_h = \text{kapsam} \cdot \text{doğruluk}_s + (1 - \text{kapsam}) \cdot \text{doğruluk}_n^\perp. \quad (3)$$

$\text{doğruluk}_n = \text{kapsam} \cdot \text{doğruluk}_n + (1 - \text{kapsam}) \cdot \text{doğruluk}_n$ (teleskopik özdeşlik) çıkarıldığında

$$\begin{aligned} \text{kazanç} &\equiv \text{doğruluk}_h - \text{doğruluk}_n \\ &= \text{kapsam} \cdot (\text{doğruluk}_s - \text{doğruluk}_n) \\ &\quad + (1 - \text{kapsam}) \cdot (\text{doğruluk}_n^\perp - \text{doğruluk}_n). \end{aligned} \quad (4)$$

Denklem 4 kesindir. $\text{doğruluk}_n^\perp \approx \text{doğruluk}_n$ olduğunda (sinirsel kolun doğruluğu sembolik kolun çekimser kaldığı girdilere bağlı olmadığında), ikinci terim kaybolur ve basit öngörü formülünü elde ederiz:

$$\text{kazanç} \approx \text{kapsam} \cdot (\text{doğruluk}_s - \text{doğruluk}_n). \quad (5)$$

3.2 Hata Sınırı

Denklem 5'in artık hatası

$$\varepsilon = (1 - \text{kapsam}) \cdot |\text{doğruluk}_n^\perp - \text{doğruluk}_n|. \quad (6)$$

Bu sınırın iki sonucu vardır. Birincisi, yüksek kapsam rejimlerinde ($\text{kapsam} \rightarrow 1$) hata kaybolur: basit formül temel olarak kesinleşir. İkincisi, düşük kapsam rejimlerinde sinirsel kolun çekimserlik alt kümesindeki davranışı kritik hale gelir. Denklem 6 çok-sınıflı deneylerimizde (Bölüm 4) tam olarak doğrulanmıştır.

4 Deneyler

4.1 Kurulum

Hibrit paradigmayı üç görev ailesi üzerinde test ediyoruz. Her görev bir sınıflandırma problemidir: bir r ilişkisiyle bağlanan (s, o) varlık çifti verildiğinde hedef etiketi tahmin et. Sembolik kol, her iki varlığın da bilinen özellikleri olduğunda kesin bir kural uygular; aksi halde çekimser kahr. Sinirsel kol, sıfırdan eğitilen küçük bir MLP veya Transformer'dır.

Sentetik çok-sınıflı. N varlık, her biri K özellik biti olacak şekilde üretiyoruz. Hedef $(\text{özellik}(s) + \text{özellik}(o)) \bmod K$ 'dır. Sembolik kolun erişemeyeceği özelliklere sahip varlıkların oranını `gizli_oran` ile kontrol ediyoruz.

Diller arası bağımlılık doğrulaması. Sekiz dil için Universal Dependencies [6] treebank'ları kullanıyoruz: Türkçe (TWT), İngilizce (EWT) [7], Almanca (GSD), Fransızca (GSD), İspanyolca (GSD), İtalyanca (ISDT), Hollandaca (Alpino) ve bir sentetik temel. Görev, bir (bağımlı, baş) bağımlılık yayının ikili doğrulamasıdır. Sembolik kol kural tabanlı bir şema doğrulayıcısıdır; sinirsel kol sıfırdan eğitilen küçük bir modeldir.

Çok-etiketli. Her girdiye K bağımsız ikili bit atanır. Hibrit karar bit düzeyinde uygulanır; doğruluk bit düzeyinde ölçülür.

4.2 Diller Arası Doğrulama

Tablo 1, sekiz veri kümesindeki gözlenen ve öngörülen kazançları raporlar. Ortalama öngörü hatası 0.008'dir; her veri kümesi $\varepsilon < 0.01$ koşulunu sağlar.

Table 1: 8 veri kümesi, 6 dil ailesinde hibrit kazanç.

Veri Kümesi	Dil	kapsam	doğ _s	doğ _n	Kazanç _{göz}	Kazanç _{ön}	ε
Sentetik	—	0.490	1.000	0.790	+0.106	+0.103	0.003
TWT	Türkçe	0.965	0.945	0.897	+0.039	+0.046	0.007
EWT	İngilizce	0.972	1.000	0.926	+0.069	+0.072	0.003
GSD	Almanca	0.971	1.000	0.948	+0.046	+0.050	0.004
GSD	Fransızca	0.979	1.000	0.956	+0.041	+0.043	0.002
GSD	İspanyolca	0.987	1.000	0.962	+0.036	+0.038	0.002
ISDT	İtalyanca	0.989	1.000	0.950	+0.048	+0.049	0.002
Alpino	Hollandaca	0.973	1.000	0.945	+0.053	+0.054	0.001

4.3 Görev Genelliği

Tablo 2, doğrulamayı üç görev tipine genişletir. Çok-sınıflı ($K = 4$) ve çok-etiketli (bit-doğruluğu) için beş tohumun ortalamasını raporluyoruz. Denklem 5, bir çok-sınıflı tohum hariç her konfigürasyonu 0.01 içinde öngörür; bu tohumun hatası (0.024), sinirsel kolun çekimserlik alt kümesindeki farklı doğruluğuyla açıklanır.

Table 2: Görev genelliği. 5 tohum ortalaması.

Görev	Ortalama ε	$\varepsilon < 0.01$ tohumlar
İkili (8 veri kümesi)	0.003	8/8
Çok-sınıflı ($K = 4$)	0.008	4/5
Çok-etiketli (bit doğruluğu)	0.005	5/5

4.4 Kesin Hata Doğrulaması

Denklem 6, artık hatanın $(1 - \text{kapsam}) \cdot |\text{doğruluk}_n^\perp - \text{doğruluk}_n|$ değerine eşit olduğunu öngörür. Bunu beş çok-sınıflı tohumda doğruluyoruz (Tablo 3).

5 Tartışma

Hibrit neden kazanıyor? Denklem 4 mekanik bir cevap verir. Sembolik kol, kendine güvendiği girdilerde doğruluk katkısı sağlar; sinirsel kol başka yerlerde doldurur. Kazanç, sembolik kol girdilerin çoğunu kapsadığında ve bu girdilerde sinirsel temelden daha doğru olduğunda

Table 3: Kesin hata özdeşliği doğrulaması.

Tohum	1 – kapsam	$ \text{doğ}_n^\perp - \text{doğ}_n $	$\varepsilon_{\text{ön}}$	$\varepsilon_{\text{göz}}$
1	0.555	0.0013	0.00072	0.0007
2	0.468	0.0050	0.00234	0.0023
3	0.510	0.0479	0.02443	0.0244
4	0.523	0.0086	0.00449	0.0045
5	0.508	0.0185	0.00939	0.0094

en büyüktür. 8 veri kümesi çalışmamızda bu rejim geçerlidir çünkü kural tabanlı UD bağımlılık doğrulaması bu görev ailesinde hem yüksek kapsamlıdır (kapsam > 0.96) hem de yüksek doğrulukludur ($\text{doğruluk}_s > 0.94$).

Kazanç neden görev büyüklüğüyle artıyor? Sentetik varlık ve ilişki ölçekleme deneylerinde (Bölüm 4), sinirsel kolun doğruluğu görev büyüdükçe düşerken sembolik kolun doğruluğu temel olarak sabit kalır. Fark $\text{doğruluk}_s - \text{doğruluk}_n$ genişler, dolayısıyla kazanç büyür. Bu, formülle tutarlıdır: sembolik kol kapasite gerektirmeyen bir oracle’dır.

Sınırlar. Sembolik kol açık bir bilgi tabanı gerektirir; keyfi alanlar için nasıl inşa edileceğini ele almıyoruz. Sinirsel temellerimiz sıfırdan eğitilen küçük modellerdir; büyük ön-eğitilmiş dil modelleriyle karşılaştırma yapmıyoruz. Diller arası kanıt UD bağımlılık doğrulamasıyla sınırlıdır; diğer NLP görevlerine genelleme iddia edilmez. Bir çok-sınıflı tohum basit formülü 0.024’te ihlal eder; kesin formül (Denklem 4) bunu sinirsel kolun alt küme bağımlı doğruluğuyla açıklar.

6 Sonuç

Bir hibrit sembolik-sinirsel paradigmanın sinirsel-temel referansa karşı kazancının, önde gelen terimi $\text{kapsam} \cdot (\text{doğruluk}_s - \text{doğruluk}_n)$ olan kesin bir ayrışımı yönetildiğini gösterdik. Formül, 6 dil ailesinde 8 veri kümesi, 3 görev tipi ve 2 metrikte doğrulandı; ortalama öngörü hatası 0.008’dir. Kesin hata terimi deneysel olarak makine hassasiyetinde doğrulanmıştır. 9.69/10 şampiyona puanının altında yatan insan değerlendirme protokolü için Krippendorff’un α ’sını kullanıyoruz [3]. Formülün hibrit sistemler için bir tasarım kılavuzu olarak hizmet etmesini umuyoruz: kazancı artırmak için sembolik kapsamı yükseltin ve sinirsel kolun alt kümeye özgü davranışının baskın olduğu düşük kapsam rejimlerinden kaçınin.

References

- [1] Yoshua Bengio et al. Hybrid ai: A roadmap for integrating neural and symbolic methods. *arXiv preprint*, 2021.
- [2] Artur d’Avila Garcez and Luis C. Lamb. Neurosymbolic AI: The 3rd wave. *Artificial Intelligence Review*, 2023.
- [3] Klaus Krippendorff. Computing Krippendorff’s alpha-reliability. *Ann Arbor, MI: University of Pennsylvania*, 2011.
- [4] Robin Manhaeve, Sebastijan Dumancic, Angelika Kimmig, Thomas Demeester, and Luc De Raedt. DeepProbLog: Neural probabilistic logic programming. In *NeurIPS*, 2018.
- [5] Gary Marcus. The next decade in ai: Four steps towards robust artificial intelligence. *arXiv preprint*, 2020.

- [6] Joakim Nivre et al. Universal dependencies v2. In *LREC*, 2020.
- [7] Natalia Silveira, Timothy Dozat, Marie-Catherine de Marneffe, Samuel Bowman, Miriam Connor, John Bauer, and Christopher D. Manning. A gold standard dependency corpus for english. In *LREC*, 2014.
- [8] Ashish Vaswani et al. Attention is all you need. In *NeurIPS*, 2017.